인적자원데이터분석입문

최종 과제 (Option A)

직원 이직 예측을 위한
로지스틱 회귀와 랜덤 포레스트 분석

2024127662 BDA 임광윤

데이터 탐색 및 전처리

[데이터 소개]

1) 데이터 셋: HR_employee_churn
2) 주요 변수: Attrition(이직 여부), Age, JobRole, MonthlyIncome 등. 총 1470개의 관측치와 35개의 변수

[데이터 전처리 과정]

결측치 처리 → 변수 타입 변환 → 상수 변수 제거 → 데이터 저장 → 이상치 탐색 및 처리

1) 결측치 처리: 숫자형 변수는 중앙값으로 대체 / 결측치가 많은 변수는 제거 (30% 이상)
2) 변수 타입 변환: 범주형 변수를 factor로 변환
3) 상수 변수 제거: 값이 동일한 변수(상수 변수)는 분석에 기여하지 않으므로 제거 (EmployeeCount, Over18, StandardHours)
4) 이상치 탐색 및 처리: 이상치를 NA로 처리하고, 결측값은 중앙값으로 대체
5) 데이터 저장: **processed_data_rf**

데이터 탐색 및 전처리

유의미한 변수 추출 (범주형)

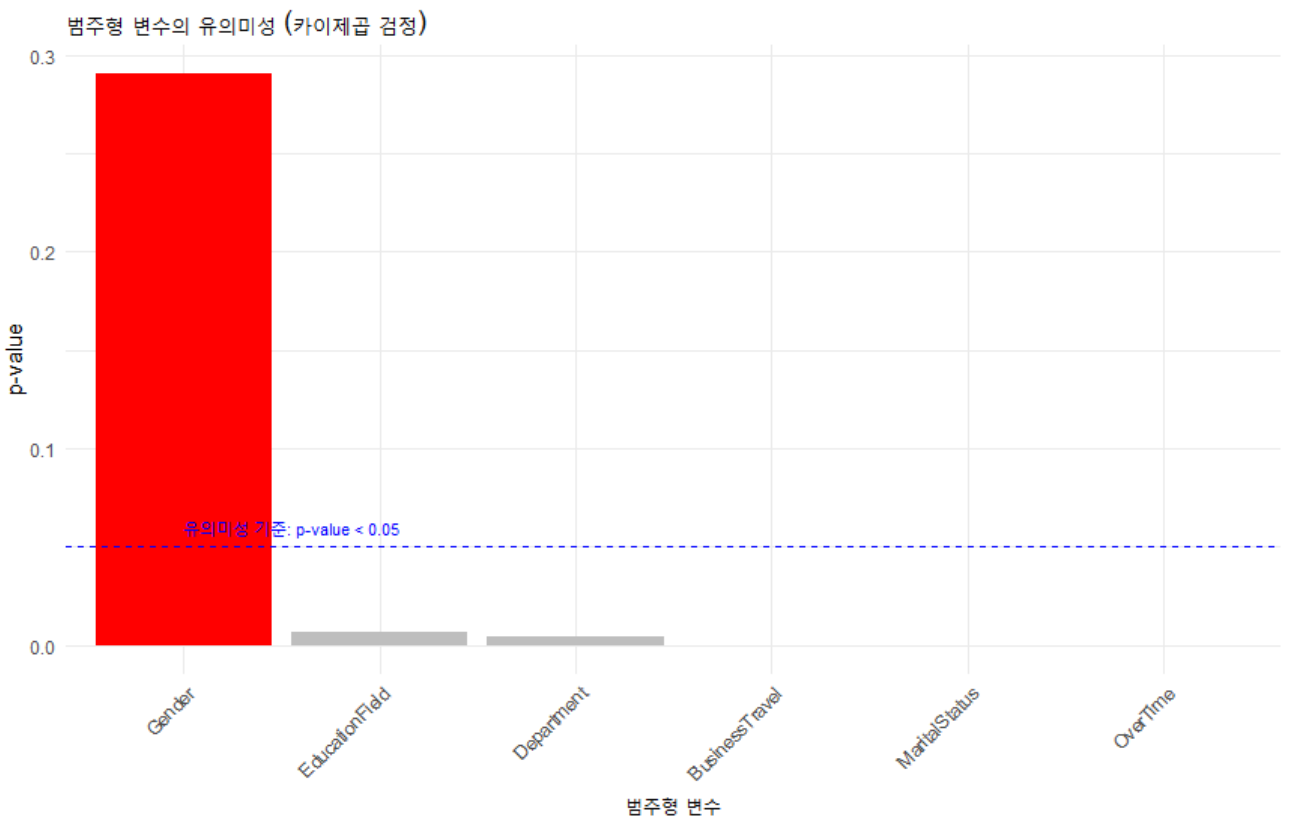

카이제곱 검정의 p-value < 0.05 일 때,
통계적으로 유의미한 관계를 가짐

[5개 변수]

- BusinessTravel
- Department
- EducationField
- MaritalStatus
- OverTime

데이터 탐색 및 전처리

유의미한 변수 추출 (숫자형)

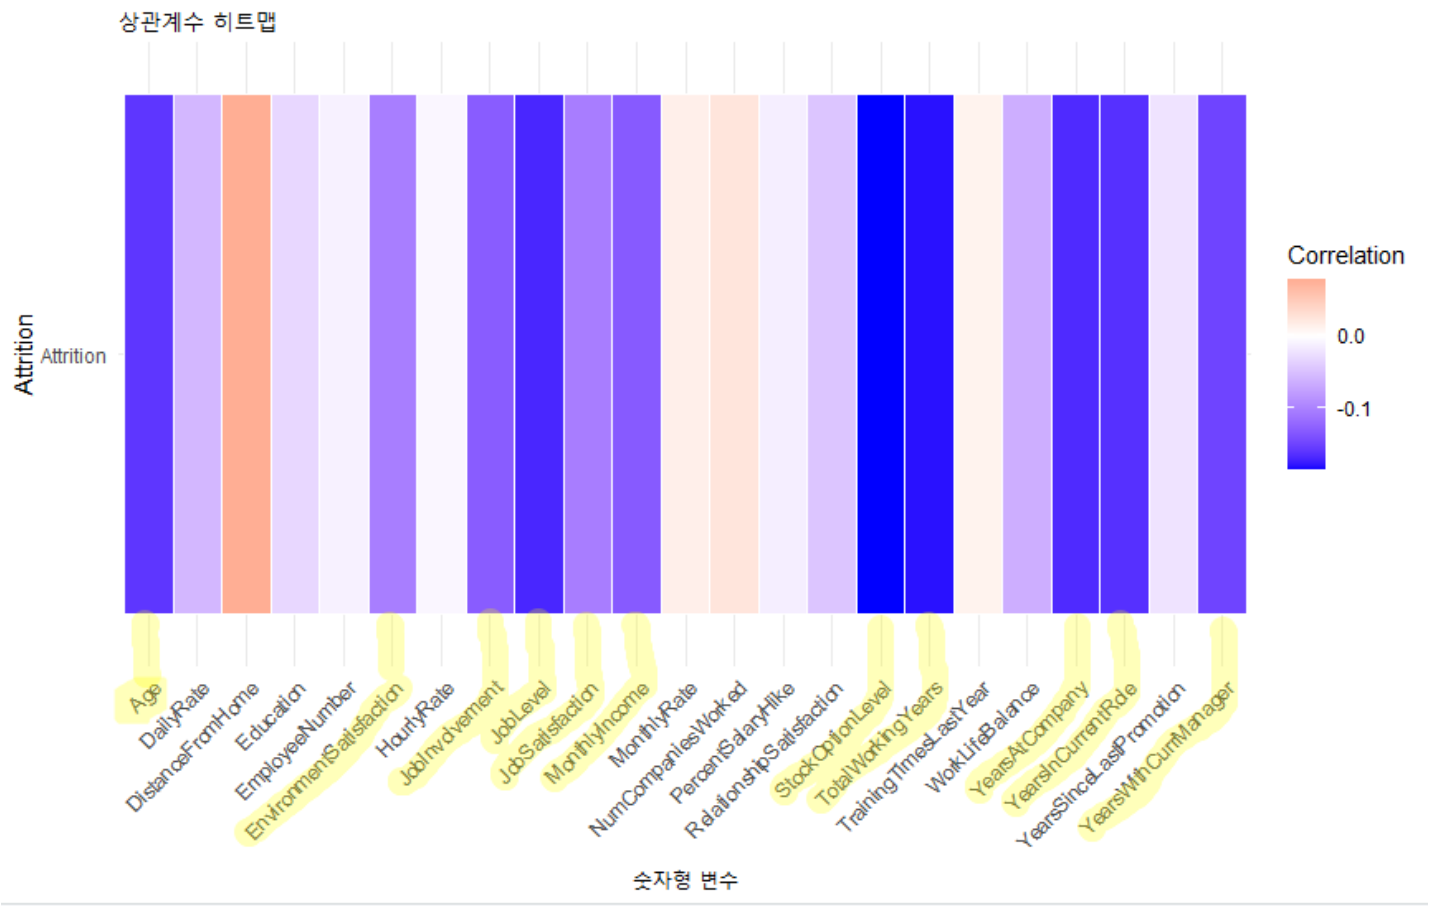

Pearson 상관계수(절대값) ≥ 0.1 일때, 약한 상관관계가 있음. 아래 11개의 변수들이 이직 여부에 영향을 줌.

[11개 변수]

- Age
- EnvironmentSatisfaction
- JobInvolvement
- JobLevel
- JobSatisfaction
- MonthlyIncome
- StockOptionLevel
- TotalWorkingYears
- YearsAtCompany
- YearsInCurrentRole
- YearsWithCurrManager

유의미한 16개의 변수를 제외한 다른 변수 제거
파일명: processed_data_rf_erase

ML 모델 선정 및 분석

[로지스틱 회귀]

모델 선정 이유:

1) 로지스틱 회귀는 종속변수(이직 여부)가 이진형(Yes/No)일 때 적합
2) 데이터에서 변수들과 이직 여부 간의 관계를 수치적으로 확인 가능
3) 단순하게 해석 가능

[랜덤 포레스트]

모델 선정 이유:

1) 비선형 관계 및 변수 간 상호작용 파악 가능
2) 변수 중요도 평가를 통해 이직 예측에 주요한 변수 도출 가능

ML 모델 선정 및 분석

[로지스틱 회귀 분석 결과]

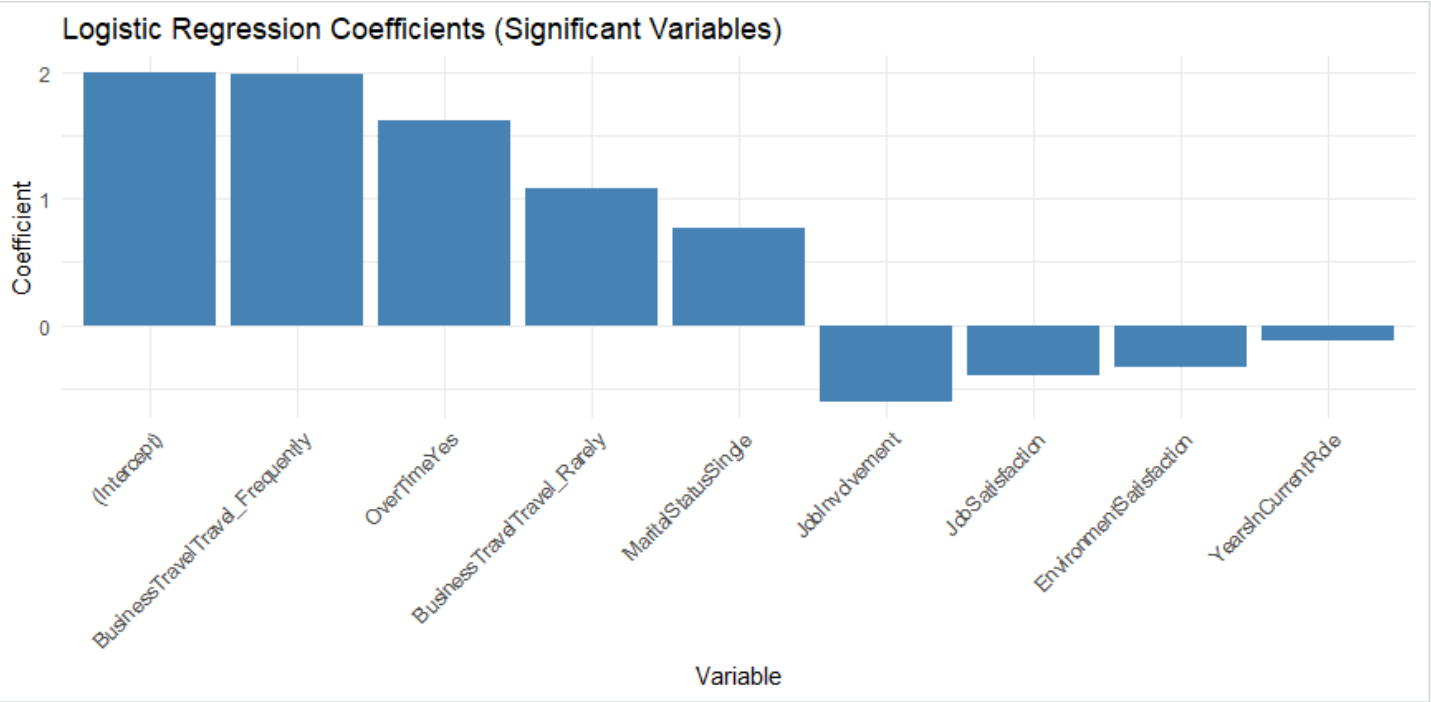

주요 변수	회귀 계수
OverTime	1.62
Travel_Frequently	1.99
Travel_Rarely	1.08
JobInvolvement	-0.61
JobSatisfaction	-0.40

▶ 양의 영향

OverTime과 BusinessTravel이 이직 예측에 가장 큰 양의 영향을 줌.

▶ 음의 영향

JobSatisfaction과 JobInvolvement은 음의 영향을 줌.

ML 모델 선정 및 분석

[랜덤 포레스트 분석 결과]

▶ Mean Decrease Accuracy

특정 변수를 제거했을 때, **모델의 정확도가 얼마나 감소하는지를 측정**하는 지표

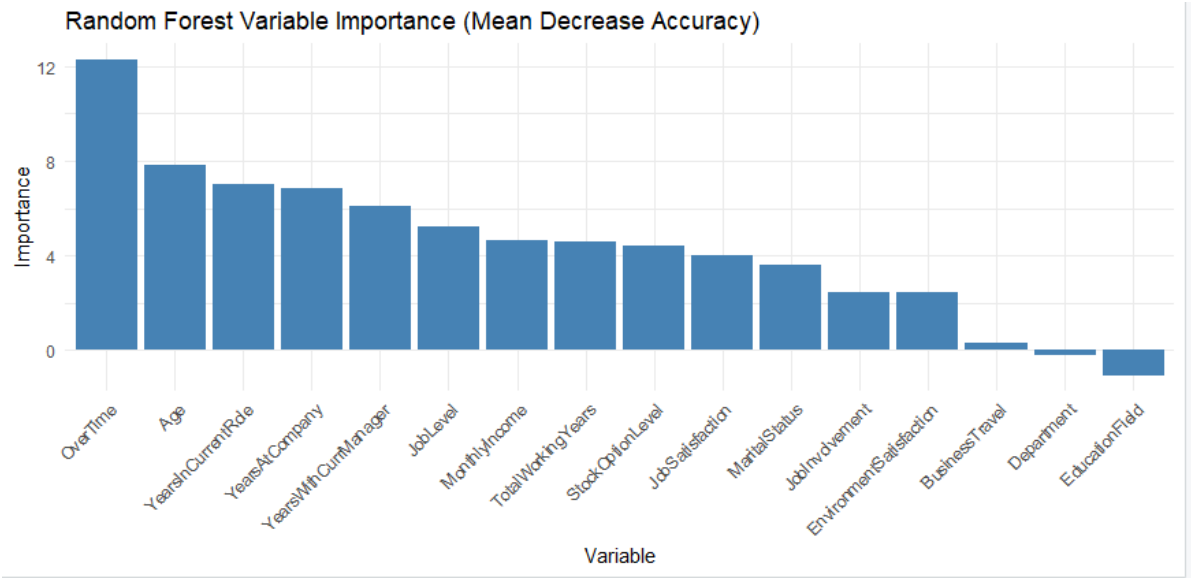

Overtime이 가장 큰 중요도(12 이상)
초과근무 여부가 모델의 예측 성능에 가장 크게 기여함

▶ Mean Decrease Gini

Gini 불순도(Gini Impurity)를 기반으로, **특정 변수가 노드 분리에 기여한 정도**를 나타내는 지표.

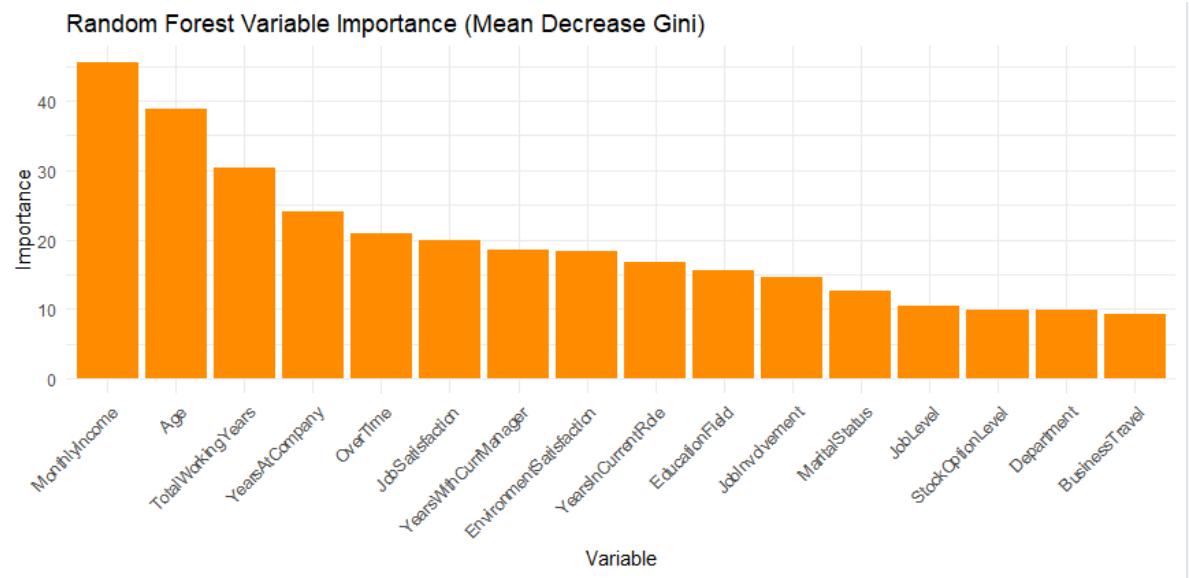

MonthlyIncome이 가장 큰 중요도(45 이상)
급여 수준이 모델의 분류 작업에 가장 크게 기여함

ML 모델 성능 비교_ ROC 곡선 비교

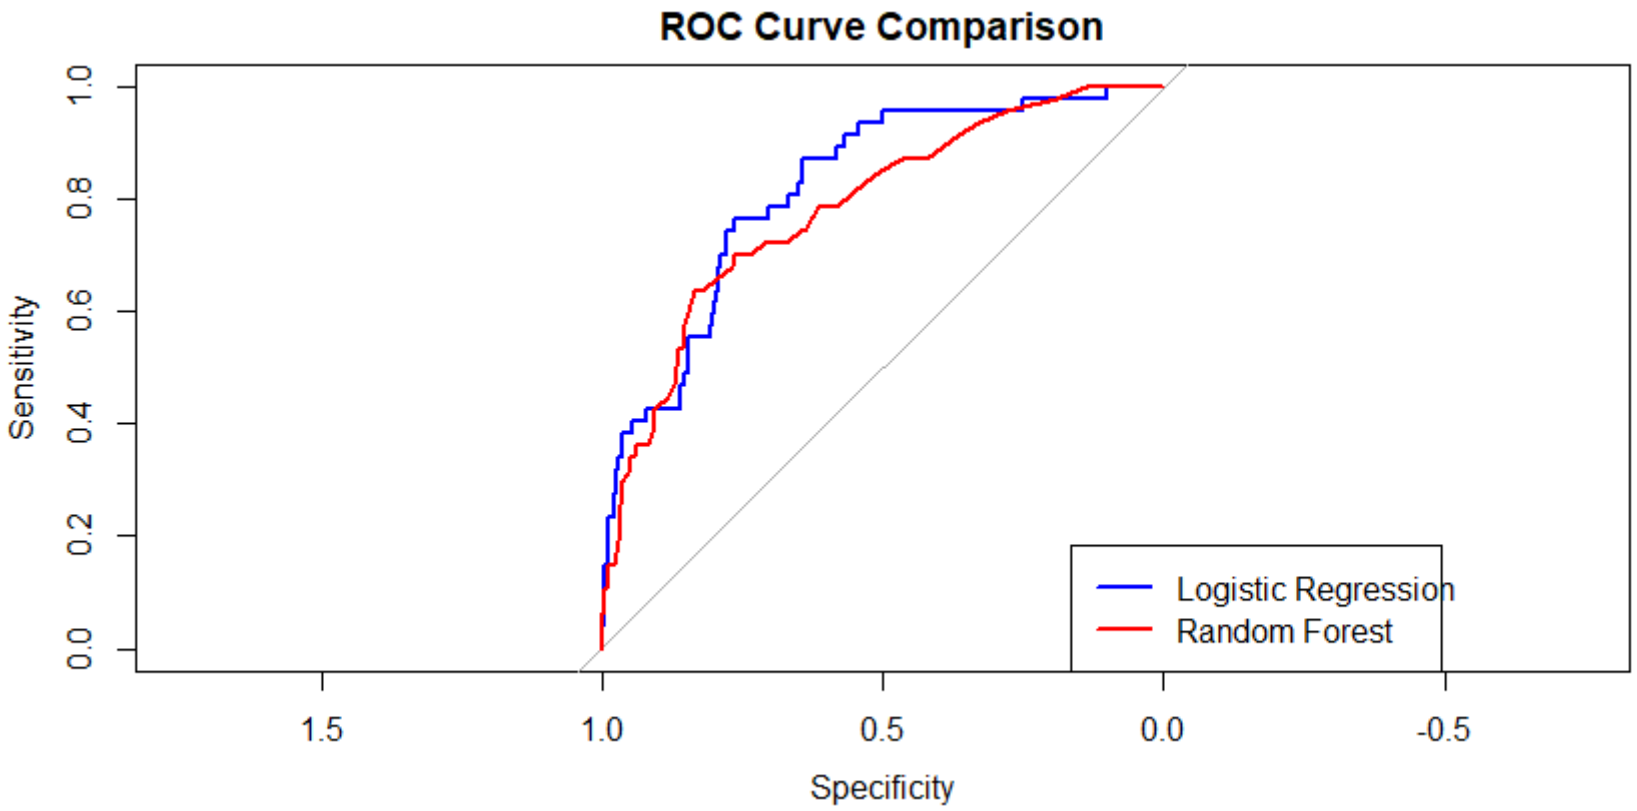

로지스틱 회귀 AUC(0.819)가 랜덤 포레스트 AUC(0.785)보다 높음.

로지스틱 회귀는 이직 여부 예측에서 더 우수한 성능을 보임.

ML 모델 성능 비교_ Confusion Matrix (혼동 행렬) 비교

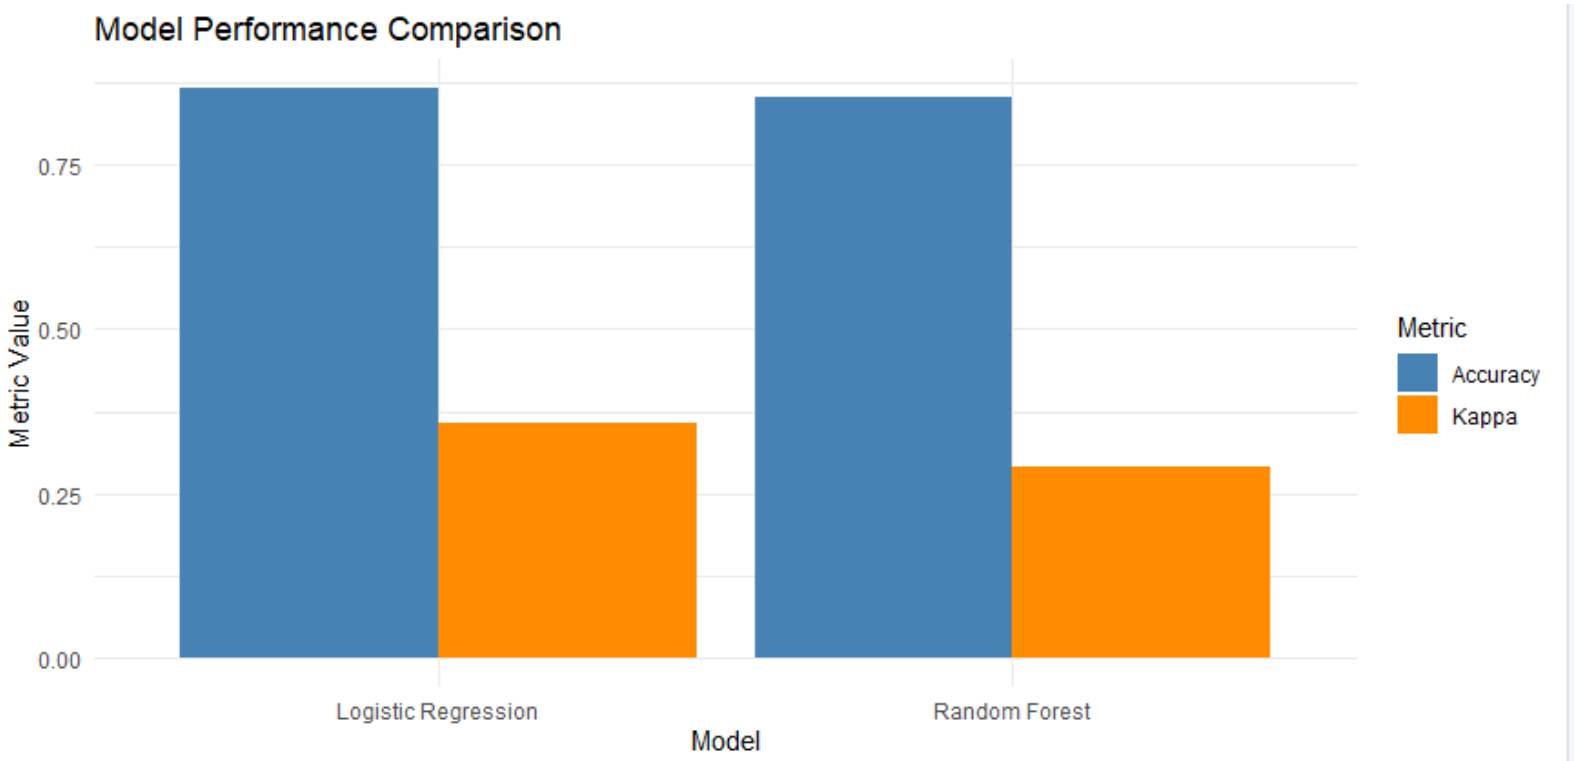

로지스틱 회귀가 더 높은 Accuracy(86.69%)와 Kappa(35.63%)를 가짐.

랜덤 포레스트는 Accuracy(85.32%)와 Kappa(29.02%)로 약간 낮은 성능.

ML 모델 성능 비교_ 결론

로지스틱 회귀 > 랜덤 포레스트

최종 분석

Point 01

랜덤 포레스트에서는 초과근무 여부가 정확도 및 지니 불순물 기준으로도 가장 높은 순위를 기록

로지스틱 회귀에서는 초과근무 여부, 빈번한 출장 등이 이직에 가장 양의 영향을 줌

Point 02

로지스틱 회귀가

랜덤 포레스트보다

우수한 성능을 보임

Point 03

로지스틱 회귀는 해석이 직관적이어서 변수의 영향을 이해하기 쉽고,

랜덤 포레스트는 비선형 및 복잡한 관계 분석에 강하지만 해석이 어려움

Point 04

로지스틱 회귀는 높은 해석 가능성과 성능으로 이직 예측에 적합하며,

랜덤 포레스트는 변수 중요도 평가와 상호작용 분석 보조적으로 사용 가능

1. 초과근무 관리: 초과근무를 줄이기 위한 정책 (예: 적정 업무 분배, 초과근무 보상 강화)을 검토.

2. 빈번한 출장 개선:
빈번한 출장(Frequent Travel)이 이직에 양의 영향을 미치므로 출장 빈도를 줄이거나 대체 업무 방안을 마련.

3. 개별 변수에 기반한 인력 관리 전략:
월급(MonthlyIncome), 직무만족(JobSatisfaction) 등 주요 변수별로 맞춤형 관리 전략을 설계.